ANALIZA KLASYFIKACYJNA WSTRZĄSÓW SEJSMICZNYCH

Projekt zaliczeniowy z przedmiotu Data Mining, 2013/14
Politechnika Warszawska
Wydział Matematyki i Nauk Informacyjnych

AUTORZY

MARCIN KOSIŃSKI, MARTA SOMMER

kosinskim@student.mini.pw.edu.pl, sommerm@student.mini.pw.edu.pl
Statystyka Matematyczna i Analiza Danych

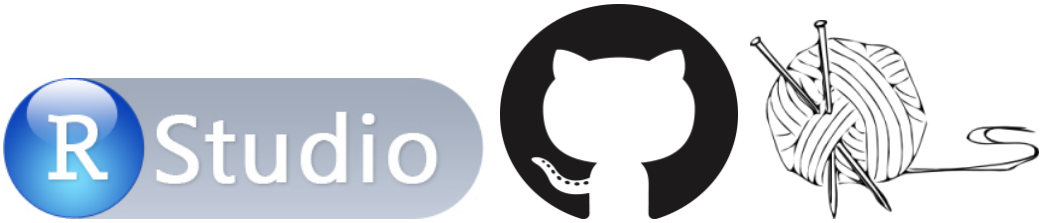

SPIS TREŚCI

Od autorów **4**
Motywacja . . . 4
Opis zmiennych w zbiorze . . . 5
Szczegóły techniczne pracy . . . 6

1 Wstępna analiza danych **7**
1.1 Podstawowe charakterystyki zmiennych . . . 7
1.1.1 Zmienne ilościowe . . . 7
1.1.2 Korelacja między zmiennymi ciągłymi . . . 7
1.1.3 Zmienna objaśniana . . . 7
1.2 Usunięcie braków danych, wstępna selekcja . . . 7

2 Analiza dyskryminacyjna **9**
2.1 Liniowa - LDA . . . 9
2.1.1 Dopasowanie modelu i predykcja . . . 9
2.1.2 Diagnostyka modelu . . . 9
2.1.3 Kroswalidacja . . . 9
2.1.4 Krzywa ROC i współczynnik AUC . . . 10
2.2 Kwadratowa - QDA . . . 10
2.2.1 Dopasowanie modelu i predykcja . . . 10
2.2.2 Diagnostyka modelu . . . 10
2.2.3 Krzywa ROC i współczynnik AUC . . . 11

3 Regresja logistyczna i regularyzacja **12**
3.1 Model pełny . . . 12
3.2 Modele oparte o kryteria informacyjne . . . 12
3.2.1 Kryterium AIC . . . 12
3.2.2 Kryterium BIC . . . 12
3.3 Porównanie z modelem pełnym . . . 12
3.4 Podsumowanie . . . 13
3.4.1 Predykcja dla modelu pełnego . . . 13
3.4.2 Predykcja dla modelu opartego na AIC . . . 13
3.4.3 Predykcja dla modelu opartego na BIC . . . 14
3.5 Uwaga! na niską jakość dopasowania . . . 14
3.6 Regularyzowana wersja regresji logistycznej . . . 14
3.7 Krzywa ROC i współczynnik AUC dla modelu wybranego przez BIC . . . 15

4 Naiwny Klasyfikator Bayesa **17**
4.1 Dopasowanie modelu i predykcja . . . 17
4.2 Diagnostyka modelu . . . 17
4.3 Krzywa ROC i współczynnik AUC . . . 17

5 Metoda k Najbliższych SąsiadóW **19**
5.1 Dopasowanie modelu i predykcja . . . 19
5.2 Diagnostyka modelu . . . 19

6 Metoda SVM **20**
6.1 Dopasowanie modelu i predykcja . . . 20
6.2 Diagnostyka modelu . . . 20
6.3 Krzywa ROC i współczynnik AUC . . . 20
6.4 Wybór optymalenych parametrów modelu . . . 21
6.5 Modele SVM z różnymi funkcjami jądrowymi . . . 22
6.5.1 Jądro liniowe . . . 22
6.5.2 Jądro wielomianowe . . . 23
6.5.3 Jądro sigmoidalne . . . 24

7 Drzewa decyzyjne **26**
7.1 Graficzna prezentacja drzew decyzyjnych . . . 26
7.2 Dopasowanie modelu i predykcja . . . 27
7.2.1 Wybór drzewa optymalnego . . . 27
7.2.2 Predykcja dla optymalnego drzewa . . . 28
7.3 Diagnostyka modelu . . . 28
7.4 Krzywa ROC i współczynnik AUC . . . 29

8 Metody łączenia drzew decyzyjnych **30**
8.1 Bagging . . . 30
8.2 Boosting . . . 31
8.3 Lasy losowe . . . 32

Zestawienie wyników dla klasyfikatorów użytych do analizy **35**

9 Krzywe ROC **35**

10 Tabela podsumowująca **36**

OD AUTORÓW

Motywacja

Górnictwo od zawsze było powiązane z niebezpieczeństwami zwanymi zagrożeniami górniczymi. Szczególnym przypadkiem takich zagrożeń są wstrząsy sejsmiczne, często nawiedzające kopalnie głębinowe. Wstrząsy sejsmiczne są najtrudniejszym do wykrycia zagrożeniem naturalnym, co czyni je pod tym względem porównywalnymi do trzęsień ziemi. Coraz większy poziom zaawansowania systemów monitorowania wstrząsów i akustyki wstrząsów pozwala nam bardziej dogłębnie zrozumieć naturę ruchów tektonicznych i określić metody przewidywania wstrząsów.

Dokładność takich metod pozostawia jednak jak dotąd wiele do życzenia. Niedostateczna precyzja metod statystycznych spowodowana jest złożonością procesów tektonicznych, jak również dużą rozbieżnością między liczbą wstrząsów o niskiej magnitudzie a liczbą wstrząsów o wysokiej magnitudzie (np. wstrząsów o energii przekraczającej $10^4 J$). W rezultacie istniejące metody statystyczne bywają niewystarczające do dokładnego przewidywania wstrząsów.

Z uwagi na realne zagrożenie życia spowodowane wstrząsami sejsmicznymi istotne jest poszukiwanie nowych sposobów lepszego wykrywania niebezpieczeństw - między innymi za pomocą metod uczenia maszynowego. Uczenie maszynowe jest w sejsmologii dziedziną wciąż rozwijającą się, gdyż obecnie stosowane metody nie są dość czułe i nie pozwalają na przewidywanie zagrożeń sejsmicznych z wystarczającą dokładnością.

Precyzyjna prognoza wzrostu aktywności tektonicznej jest niezwykle istotna w praktycznym zapobieganiu zagrożeniom. Dlatego właśnie postanowiliśmy przyjrzeć się zestawowi danych dotyczących prawdziwych problemów sejsmologicznych, z którymi zmaga się współczesna statystyka stosowana.

Opis zmiennych w zbiorze

Zbiór wykorzystany w analizie cechuje się niezbalansowanym rozkładem przypadków występowania i braku występowania cechy, dla której ma być zadana predykcja. Na blisko ponad 2000 przypadków tylko 170 reprezentuje klasę 1. Będzie to główny problem, przewijający się przez cały proces analizy danych.

Tabela 1: Opis zmiennych ze zbioru `Seismic-bumps`.

Zmienna	Opis
seismic	wynik oceny zagrożenia sejsmicznego w czasie danej zmiany oszacowanego metodą pomiarów sejsmicznych (a - brak zagrożenia, b - niski poziom zagrożenia, c - wysoki poziom zagrożenia, d - niebezpieczeństwo wstrząsu)
seismoacoustic	wynik oceny zagrożenia sejsmicznego w czasie danej zmiany oszacowanego metodą pomiarów sejsmoakustycznych
shift	informacja na temat typu zmiany, (W - ekipa wydobywająca węgiel, N - zmiana przygotowawcza)
genergy	poziom energii sejsmicznej zarejestrowany przez najbardziej aktywny (GMax) spośród geofonów monitorujących tunel
gpuls	liczba drgań zarejestrowana[1] przez Gmax
gdenergy	odchylenie poziomu energii zarejestrowanej[1] przez Gmax od średniej zarejestrowanej podczas ostatnich 8 zmian
gdpuls	odchylenie liczby drgań zarejestrowanej[1] przez Gmax od średniej zarejestrowanej podczas ostatnich 8 zmian
ghazard	wynik oceny zmiany zagrożenia sejsmicznego na zmianie oszacowany metodą `seismoacoustic` tylko przez geofonu Gmax
nbumps	liczba tąpnięć sejsmicznych[1]
nbumps2	liczba tąpnięć sejsmicznych[1] w zakresie $[10^2, 10^3)$
nbumps3	liczba tąpnięć sejsmicznych[1] w zakresie $[10^3, 10^4)$
nbumps4	liczba tąpnięć sejsmicznych[1] w zakresie $[10^4, 10^5)$
nbumps5	liczba tąpnięć sejsmicznych[1] w zakresie $[10^5, 10^6)$
nbumps6	liczba tąpnięć sejsmicznych[1] w zakresie $[10^6, 10^7)$
nbumps7	liczba tąpnięć sejsmicznych[1] w zakresie $[10^7, 10^8)$
nbumps89	liczba tąpnięć sejsmicznych[1] w zakresie $[10^8, 10^{10})$
energy	całkowita energia tąpnięć sejsmicznych[1]
maxenergy	maksymalna energia tąpnięć sejsmicznych[1]
class	zmienna decyzyjna – czy na kolejnej zmianie wystąpi silne tąpnięcie

[1] Zarejestrowana podczas poprzedniej zmiany

Szczegóły techniczne pracy

Analiza została przeprowadzona w pakiecie statystycznym R, wersja 3.1.0. Tekst raportu został złożony przy pomocy pakietu knitr, który umożliwia załączanie wyników i rezultatów z funkcji R w programie do składu publikacji LaTeX. Projekt został przeprowadzony przy wsparciu systemu kontroli wersji Git, który czuwał nad integracją plików i optymalizacją pracy zespołowej. Korzyść z zastosowania takiego rozwiązania techonologicznego była taka, że w dwie osoby mogliśmy wspólnie pracować na wielu plikach .Rnw jednocześnie bez konfliktów i z możlisie szybkim przekazem plików. Do połączenia pakietu R z systemem kontroli wersji Git wykorzystano pakiet `devtools`, wspomagający integrację pakietu R z GitHubem (https://github.com). Ostatecznie dzięki systemowi kontroli wersji można śledzic postępy w pracach i zaangażowanie poszczególnych osób w sukces projektu. Poniżej screen z aktywności przy obecnym projekcie:

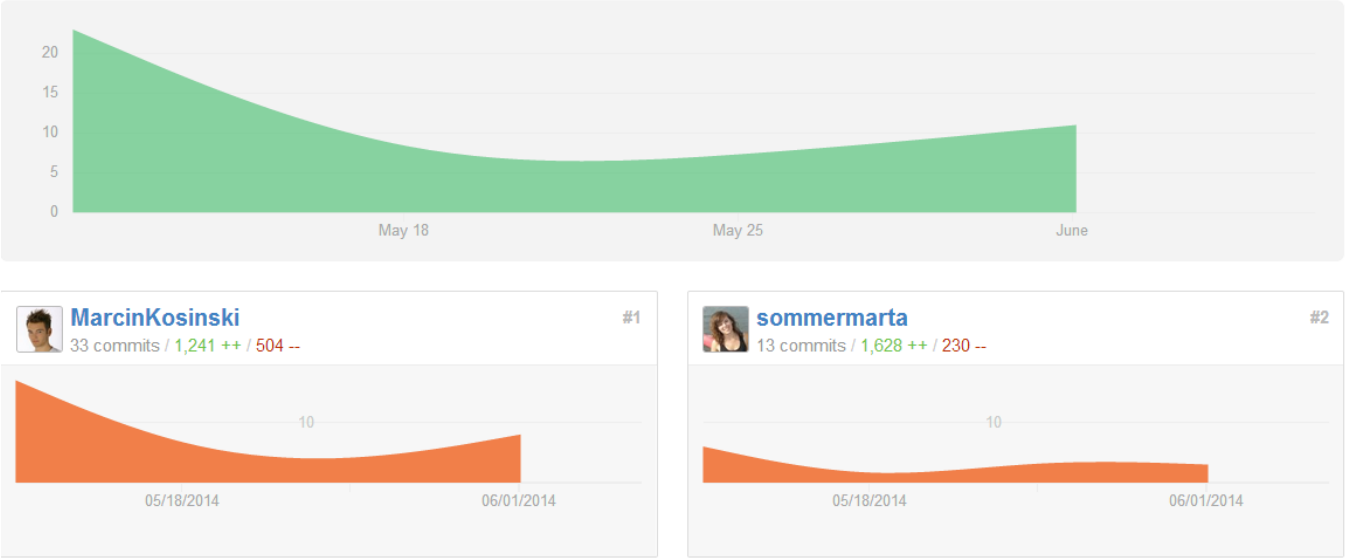

Repozytorium, w którym dostępne są wszystkie pliki jest dostępne pod adresem: https://github.com/MarcinKosinski/DM1.

ROZDZIAŁ 1

WSTĘPNA ANALIZA DANYCH

1.1 Podstawowe charakterystyki zmiennych

1.1.1 Zmienne ilościowe

	genergy	gpuls	gdenergy	gdpuls	nbumps	energy	maxenergy
Odchylenie St	229200.51	562.65	80.32	63.17	1.36	20450.83	19357.45
Wariancja	52532873277.49	316577.88	6451.15	3990.01	1.86	418236579.49	374711059.50
Mediana	25485.00	379.00	-6.00	-6.00	0.00	0.00	0.00
Średnia	90242.52	538.58	12.38	4.51	0.86	4975.27	4278.85

Tabela 1.1: Podstawowe statystyki agregujące dla zmiennych ciągłych.

1.1.2 Korelacja między zmiennymi ciągłymi

```
          genergy gpuls gdenergy gdpuls nbumps nbumps2 nbumps3 nbumps4 nbumps5 energy maxenergy
genergy      1.00  0.76     0.39   0.39   0.49    0.34    0.39    0.23    0.04   0.48      0.47
gpuls        0.76  1.00     0.46   0.58   0.31    0.22    0.21    0.22    0.04   0.30      0.30
gdenergy     0.39  0.46     1.00   0.80   0.07    0.08    0.01    0.07    0.06   0.07      0.06
gdpuls       0.39  0.58     0.80   1.00   0.10    0.09    0.04    0.09    0.07   0.10      0.09
nbumps       0.49  0.31     0.07   0.10   1.00    0.76    0.76    0.34    0.09   0.96      0.94
nbumps2      0.34  0.22     0.08   0.09   0.76    1.00    0.31    0.15    0.00   0.59      0.56
nbumps3      0.39  0.21     0.01   0.04   0.76    0.31    1.00    0.16    0.06   0.79      0.78
nbumps4      0.23  0.22     0.07   0.09   0.34    0.15    0.16    1.00   -0.02   0.45      0.45
nbumps5      0.04  0.04     0.06   0.07   0.09    0.00    0.06   -0.02    1.00   0.13      0.13
energy       0.48  0.30     0.07   0.10   0.96    0.59    0.79    0.45    0.13   1.00      1.00
maxenergy    0.47  0.30     0.06   0.09   0.94    0.56    0.78    0.45    0.13   1.00      1.00
```

1.1.3 Zmienna objaśniana

Poniżej widoczny jest podział klas w naszym zbiorze danych:

```
summary(se[, 16])
```

```
   0    1
2414  170
```

1.2 Usunięcie braków danych, wstępna selekcja

W naszym zbiorze nie występują braki danych.

Na pierwszy rzut oka widać, że niektóre zmienne są zupełnie nieistotne lub bardzo ze sobą skorelowane, dlatego chcielibyśmy od razu usunąć je z analizy. Przyjrzyjmy się naszym danym:

```
  seismic seismoacoustic shift genergy gpuls gdenergy gdpuls ghazard nbumps nbumps2 nbumps3 nbumps4
1       a              a     N   15180    48       -72    -72       a      0       0       0       0
2       a              a     N   14720    33       -70    -79       a      1       0       1       0
3       a              a     N    8050    30       -81    -78       a      0       0       0       0
  nbumps5 nbumps6 nbumps7 nbumps89 energy maxenergy class
1       0       0       0        0      0         0     0
2       0       0       0        0   2000      2000     0
3       0       0       0        0      0         0     0
```

Zacznijmy od zmiennych *nbumps6, nbumps7* oraz *nbumps89*. Są to zmienne ilościowe, wszystkie jednak przyjmują wartość zero. Niczego więc nie wnoszą one do naszej analizy. Zastąpmy je więc przez zmienną *nbumps5* (a raczej rozszerzmy definicję zmiennej *nbumps5*), która będzie od tej pory definiować liczbę wstrzasów sejsmicznych w zakresie $[10^5, 10^{10})$. Z analizy wyrzucimy również zmienną *maxenergy*, która wydaje się silnie zależna od zmiennej *energy*.

Kolejną zmienną, którą usuniemy z analizy będzie zmienna *nbumps*, która jest liniowo zależna od zmiennych *nbumps2, nbumps3, nbumps4* i *nbumps5*.

Zajmijmy się jeszcze zmiennymi nominalnymi. Niestety nie każda metoda, którą będziemy stosować do analizy (np. QDA) dobrze sobie z nimi radzi. Będziemy więc pracować na dwóch zestawach danych. Tam, gdzie się da, będziemy korzystać z danych oryginalnych. W reszcie metod zamienimy sobie dane nominalny na dane ilościowe w następujący sposób:

Zmienną *seismic* przyjmującą wartości ze zbioru $\{a, b, c, d\}$ zamienimy na zmienną *seismic2* przyjmuącą wartości $\{0, 1, 2, 3\}$. W analogiczny sposób zamienimy zmienną *sesismoacoustic* na zmienną *sesismoacoustic2* oraz zmienną *ghazard* na zmienną *ghazard2*. Możemy tak zrobić, gdyż ich wartości reprezentują pewien porządek (a - małe, d - duże). Tak nie jest niestety w przypadku zmiennej *shift*. Dlatego dla niej stworzymy zmienną indykatorową *shift2* równą 1, gdy na zmianie byli górnicy, a 0, gdy na zmianie była ekipa przygotowawcza.

W ten sposób nasz zbiór danych w formie nominalnej przedstawia się następująco:

```
  seismic seismoacoustic shift genergy gpuls gdenergy gdpuls ghazard nbumps2 nbumps3 nbumps4
1       a              a     N   15180    48       -72    -72       a       0       0       0
2       a              a     N   14720    33       -70    -79       a       0       1       0
3       a              a     N    8050    30       -81    -78       a       0       0       0
  nbumps5 energy class
1       0      0     0
2       0   2000     0
3       0      0     0
```

A zbiór danych w formie liczbowej następująco:

```
  seismic2 seismoacoustic2 shift2 genergy gpuls gdenergy gdpuls ghazard2 nbumps2 nbumps3 nbumps4
1        0               0      0   15180    48       -72    -72        0       0       0       0
2        0               0      0   14720    33       -70    -79        0       0       1       0
3        0               0      0    8050    30       -81    -78        0       0       0       0
  nbumps5 energy class
1       0      0     0
2       0   2000     0
3       0      0     0
```

ROZDZIAŁ 2

ANALIZA DYSKRYMINACYJNA

2.1 Liniowa - LDA

2.1.1 Dopasowanie modelu i predykcja

Dopasujmy model LDA do naszych danych na zbiorze treningowym:

```
mod_lda <- lda(class ~ ., data = Train)
```

Zróbmy predykcję na zbiorze testowym:

```
pred_klas <- predict(mod_lda, newdata = Test)$class
pred_praw <- predict(mod_lda, newdata = Test)$posterior[, 2]
```

2.1.2 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 793  45
              1  18   6
```

A procent poprawnego dopasowania, czułość i precyzja następująco:

```
procent(tab)

[1] 92.69

czulosc(tab)

[1] 0.25

precyzja(tab)

[1] 0.1176
```

Mimo że procent poprawnej klasyfikacji jest bardzo wysoki (ponad 92%), to nie możemy tu mówić o dobrym klasyfikatorze. Wyraźnie widać, że nasza LDA klasyfikuje prawie wszystkie obserwacje jako 0, a przez fakt, że próba nie jest symetryczna (zera stanowią znaczną większość próby) osiągamy wysoki procent poprawnej klasyfikacji. O tym, że rzeczywiście model nie jest najlepszy powiedzą nam również czułość (25%) i precyzja (12%).

2.1.3 Kroswalidacja

Sprawdźmy jeszcze jakość dopasowanego modelu przeprowadzając kroswalidację dziesiętnokrotną. Oto otrzymane rezultaty:

```
mean(pro)  # procent poprawnej klasyfikacji

[1] 92.02
```

```
mean(czu)  # czulosc
```

```
[1] 0.3199
```

```
mean(pre)  # precyzja
```

```
[1] 0.1489
```

Czułość i precyzja nieco się poprawiły.

2.1.4 Krzywa ROC i współczynnik AUC

I na koniec wyznaczmy krzywą ROC:

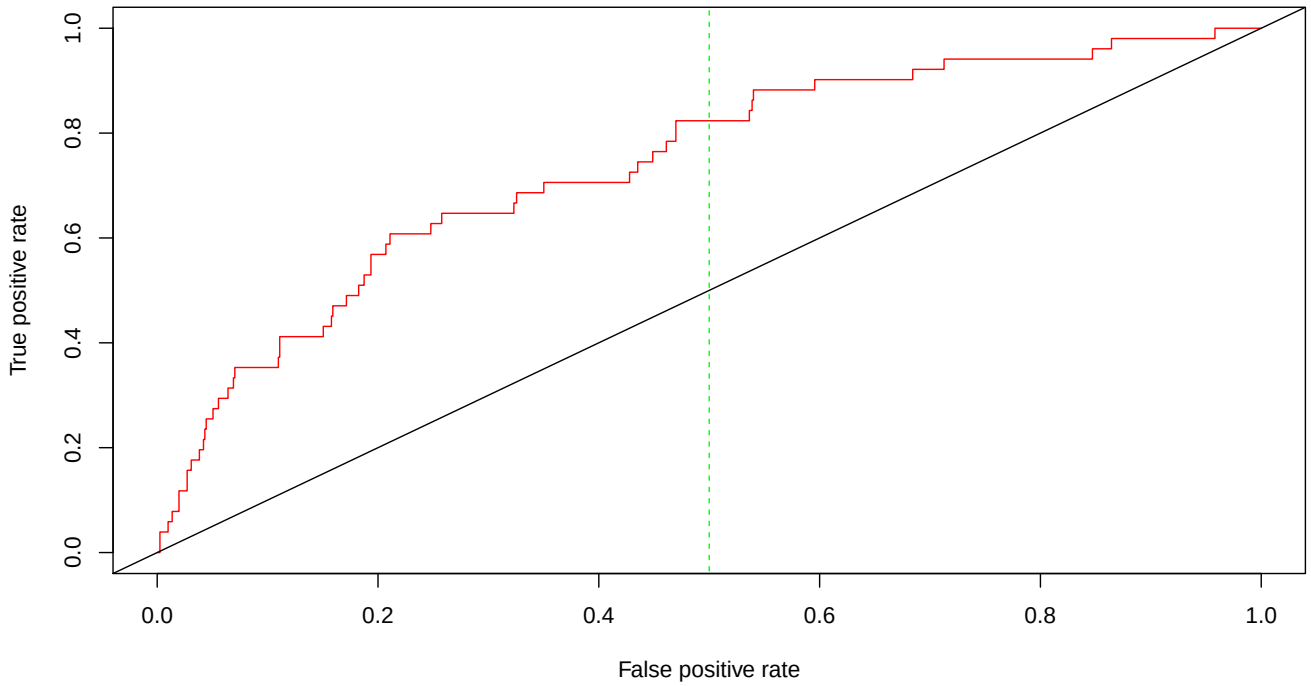

Współczynnik AUC wynosi:

```
[1] 0.7398
```

2.2 Kwadratowa - QDA

2.2.1 Dopasowanie modelu i predykcja

Dopasujmy model QDA do naszych danych na zbiorze treningowym:

```
mod_qda <- qda(class ~ ., data = Train2)
```

Zróbmy predykcję na zbiorze testowym:

```
pred_klas <- predict(mod_qda, newdata = Test2)$class
pred_praw <- predict(mod_qda, newdata = Test2)$posterior[, 2]
```

2.2.2 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
                klasy_prawdziwe
predykcja_klasy   0   1
              0 734  34
              1  77  17
```

A procent poprawnego dopasowania, czułość i precyzja następująco:

```
procent(tab)

[1] 87.12

czulosc(tab)

[1] 0.1809

precyzja(tab)

[1] 0.3333
```

No i znów (podobnie jak dla LDA) model nie jest najlepiej dopasowany. Mimo to wyraźnie widać znaczną poprawę (szczególnie precyzji).

2.2.3 Krzywa ROC i współczynnik AUC

I na koniec wyznaczmy krzywą ROC:

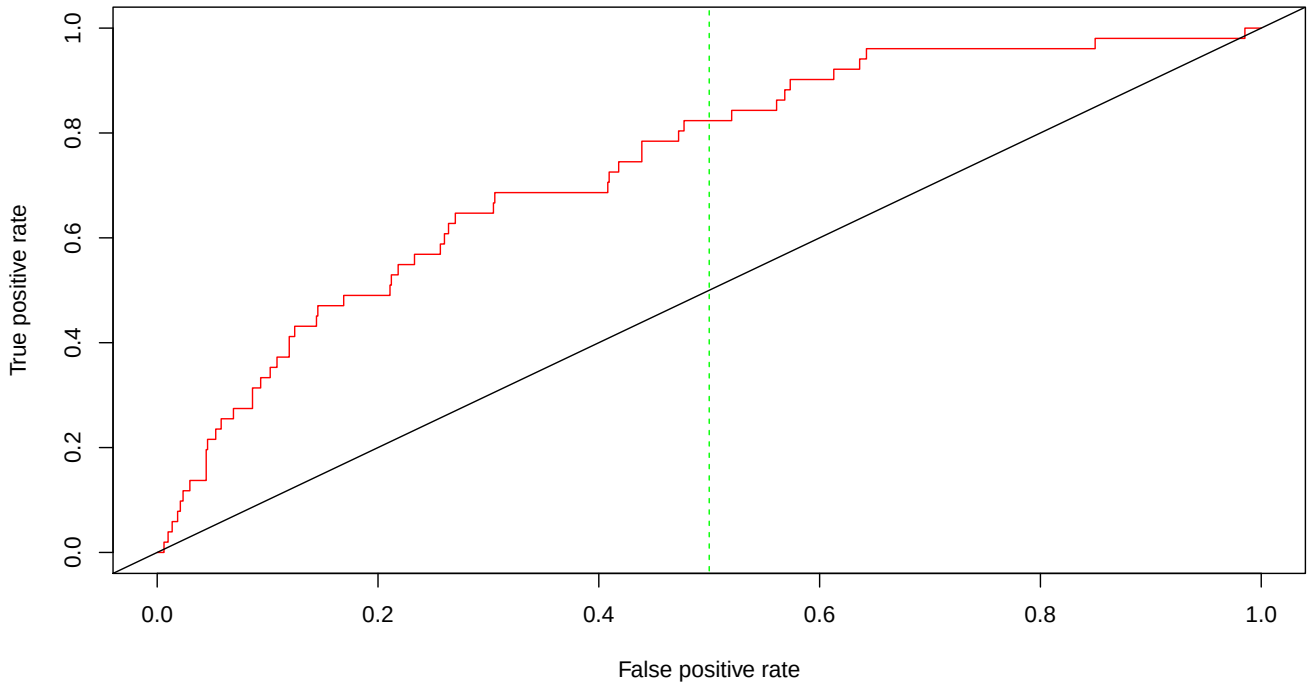

Współczynnik AUC wynosi:

```
[1] 0.7387
```

ROZDZIAŁ 3

REGRESJA LOGISTYCZNA I REGULARYZACJA

3.1 Model pełny

Po wybraniu zbioru testowego i treningowego w proporcjach 1:2 przeprowadzono regresję logistyczną:

```
Se.logit <- glm(class ~ ., data = Train, family = "binomial")
```

Przy tak ustawionym ziarnie losowania `set.seed(456)` istotnymi zmiennymi w modelu są zmienne shift w grupie `W` oraz zmienne `gpuls`, `nbumps2` i `nbump3`. Przy niektórych innych ziarnach również istotną zmienna w modelu był `genergy` - co widać po małej wartości krytycznej-p.

3.2 Modele oparte o kryteria informacyjne

Korzystając z funkcji `step()` wyliczono modele oparte o kryteria informacyjne AIC oraz BIC.

3.2.1 Kryterium AIC

Stosując metodę wsteczną otrzymano model:

```
class ~ seismic + shift + genergy + gpuls + gdenergy + nbumps2 +
    nbumps3
```

Kryterium oparte o AIC wybrało zmienne, które były istotne w modelu pełnym oraz dodatkowo zmienne, których p-wartości były bliskie 0.05. Jako że kryterium AIC jest konserwatywne i nie odrzuca zmiennych, nie dziwne, że w modelu zostały uwzględnione również zmienne o p-wartości zbliżonej do 0.05.

3.2.2 Kryterium BIC

Stosując metodę wsteczną otrzymano model:

```
class ~ shift + gpuls + nbumps2 + nbumps3
```

Kryterium oparte o BIC wybrało tylko te zmienne, które były istotne w modelu pełnym, czyli model `shift + gpuls + nbumps2 + nbumps3`. Ponieważ prawdopodobieństwo wybrania przez kryterium BIC poprawnego modelu dąży do 1, a zbiór ucząc miał ponad 1800 obserwacji, zakładam, że model wybrany przez BIC jest odpowiedni.

3.3 Porównanie z modelem pełnym

W celu przetestowania adekwatności wyboru modelu pełnego przeprowadzono test Chi-kwadrat, by porównać go z modelami mniejszymi:
Test: kryterium AIC vs model pełny

```
anova(Se.logit.aic, Se.logit, test = "Chi")
```

```
Analysis of Deviance Table

Model 1: class ~ seismic + shift + genergy + gpuls + gdenergy + nbumps2 +
    nbumps3
Model 2: class ~ seismic + seismoacoustic + shift + genergy + gpuls +
    gdenergy + gdpuls + ghazard + nbumps2 + nbumps3 + nbumps4 +
    nbumps5 + energy
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      1714        731
2      1706        726  8     5.08     0.75
```

Ponieważ test nie odrzucił hipotezy zerowej (p-wartość jest większa o zakładanego poziomu istotności 0.05) to nie ma podstaw by nie zakładać, że model pełny może być uproszczony do modelu mniejszego wybranego przez kryterium informacyjne AIC.

Test: kryterium BIC vs model pełny

```
anova(Se.logit.bic, Se.logit, test = "Chi")

Analysis of Deviance Table

Model 1: class ~ shift + gpuls + nbumps2 + nbumps3
Model 2: class ~ seismic + seismoacoustic + shift + genergy + gpuls +
    gdenergy + gdpuls + ghazard + nbumps2 + nbumps3 + nbumps4 +
    nbumps5 + energy
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      1717        741
2      1706        726 11     14.5      0.2
```

Ponieważ test nie odrzucił hipotezy zerowej (p-wartość jest większa o zakładanego poziomu istotności 0.05) to nie ma podstaw by nie zakładać, że model pełny może być uproszczony do modelu mniejszego wybranego przez kryterium informacyjne BIC. **Test: kryterium AIC vs kryterium BIC**

```
anova(Se.logit.aic, Se.logit.bic, test = "Chi")

Analysis of Deviance Table

Model 1: class ~ seismic + shift + genergy + gpuls + gdenergy + nbumps2 +
    nbumps3
Model 2: class ~ shift + gpuls + nbumps2 + nbumps3
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1      1714        731
2      1717        741 -3    -9.46    0.024 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Wartość krytyczna tetsu jest mniejsza od poziomu istotności zatem należy odrzucić hipotezę zerową i przyjąć model wybrany za pomocą kryterium BIC.

3.4 Podsumowanie

Regresja liniowa oparta o kryterium informacyjne BIC i regułę krokową wsteczną wybrało do modelu zmienne jako adekwatne i istotne: `shift + gpuls + nbumps2 + nbumps3`.

3.4.1 Predykcja dla modelu pełnego

Wywołanie i stworzenie klasyfikatora dla modelu pełnego wygląda następująco:

```
P <- predict(Se.logit, newdata = Test, type = "response")
Pred <- ifelse(P > 0.5, 1, 0)
```

Poprawność dopasowania wynosi:

```
Tab <- tabela(Pred, Test$class)
100 * sum(diag(Tab))/sum(Tab)

[1] 93.97
```

3.4.2 Predykcja dla modelu opartego na AIC

Wywołanie i stworzenie klasyfikatora dla modelu opartego na AIC wygląda następująco:

```
P.aic <- predict(Se.logit.aic, newdata = Test, type = "response")
Pred.aic <- ifelse(P.aic > 0.5, 1, 0)
```

Poprawność dopasowania wynosi:

```
Tab.aic <- tabela(Pred.aic, Test$class)
100 * sum(diag(Tab.aic))/sum(Tab.aic)

[1] 93.97
```

3.4.3 Predykcja dla modelu opartego na BIC

Wywołanie i stworzenie klasyfikatora dla modelu opartego na BIC wygląda następująco:

```
P.bic <- predict(Se.logit.bic, newdata = Test, type = "response")
Pred.bic <- ifelse(P.bic > 0.5, 1, 0)
```

Poprawność dopasowania wynosi:

```
Tab.bic <- tabela(Pred.bic, Test$class)
100 * sum(diag(Tab.bic))/sum(Tab.bic)

[1] 93.97
```

Wartości poprawności dopasowania w każdym z modeli wychodzą bardzo wysokie. Rzędu 94%. Nie jest to żaden błąd, gdyż np. 5 pierwszych predykcji wygląda różnie:

```
formatC(c(P[1:5], P.aic[1:5], P.bic[1:5]), digits = 3, format = "f")

      6       7       8      13      15       6       7       8      13      15       6       7
"0.035" "0.078" "0.021" "0.052" "0.018" "0.036" "0.080" "0.021" "0.053" "0.018" "0.038" "0.097"
      8      13      15
"0.022" "0.063" "0.021"
```

3.5 Uwaga! na niską jakość dopasowania

Modele dopasowane w poprzednim podrozdziale nie są poprawne pomimo, że błąd klasyfikacji w każdym z przypadków wynosił po 6%. Proszę spojrzeć na tabelę klasyfikacyją w każdym z tych modeli:

```
Tab

               klasy_prawdziwe
predykcja_klasy   0   1
              0 808  49
              1   3   2

Tab.aic

               klasy_prawdziwe
predykcja_klasy   0   1
              0 808  49
              1   3   2

Tab.bic

               klasy_prawdziwe
predykcja_klasy   0   1
              0 809  50
              1   2   1
```

W każdym z modelu około 50 przypadków wystąpień silnych wstrząsów przy następnej zmianie załogi górnikow nie zostało poprawnie zaklasyfikowanych. Oznacza to, że nasz klasyfikator jest błędny i klasyfikuje wszystkie przypadki do cechy 0, oznaczającej, że niebezpieczeństwa nie będzie i że silne wstrząsy nie nastąpią. Pomimo małego błędu predykcji klasyfikator oparty na modelu regresji liniowej jest nieadekwatny i błędny.

3.6 Regularyzowana wersja regresji logistycznej

```
rlas <- glmnet(as.matrix(se_r[, -14]), se_r[, 14], family = "binomial", alpha = 0, lambda.min = 1e-04)
plot(rlas)
```

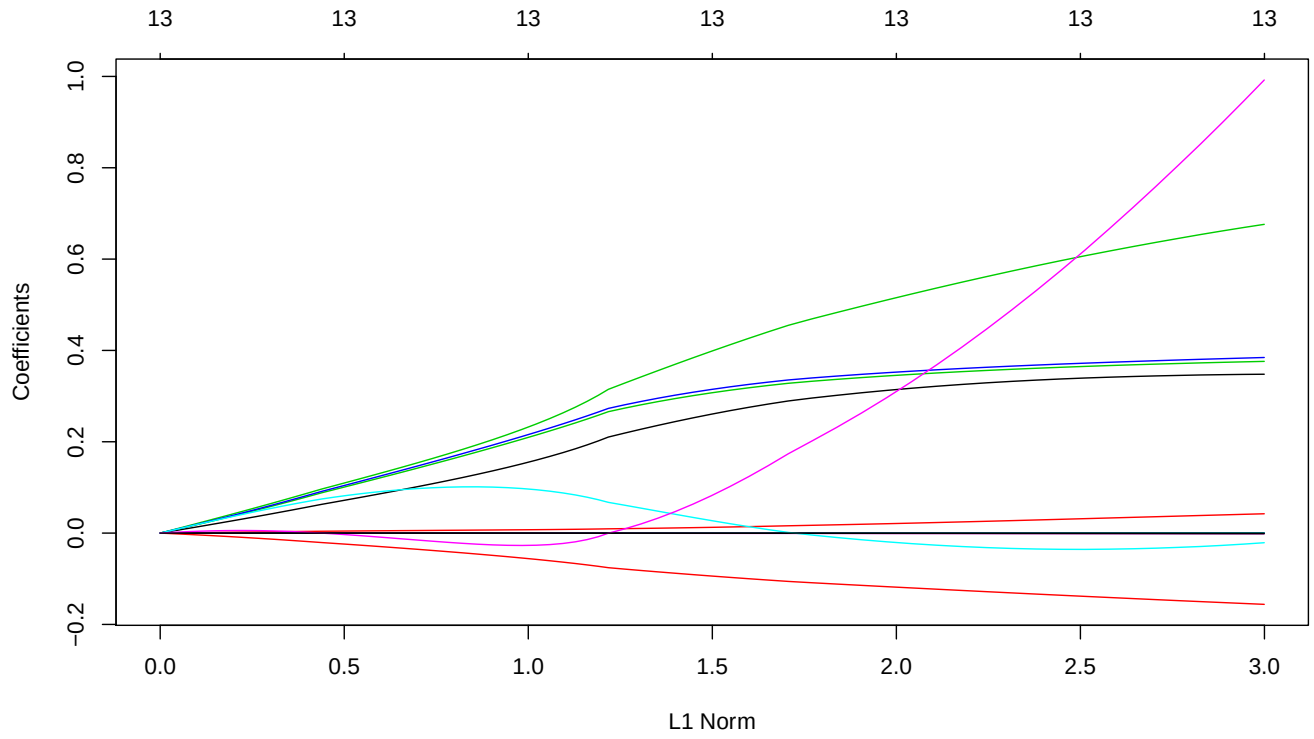

Powyżej widać, które zmienne dołączane są w którym kroku algorytmu.

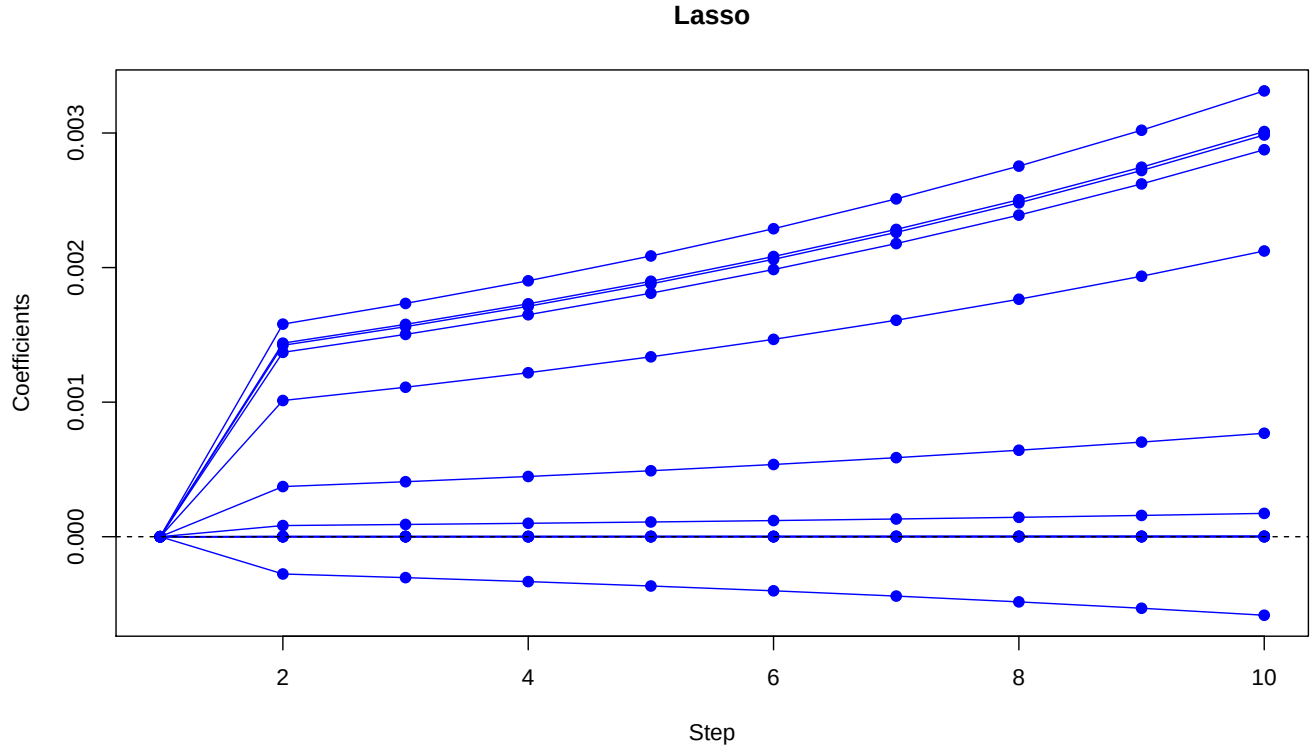

Powyżej widać, które zmienne dołączane są w którym kroku algorytmu, jednak inna metodą narysowan i z inną skalą. Teraz widać więcej.

3.7 Krzywa ROC i współczynnik AUC dla modelu wybranego przez BIC

I na koniec wyznaczmy krzywą ROC:

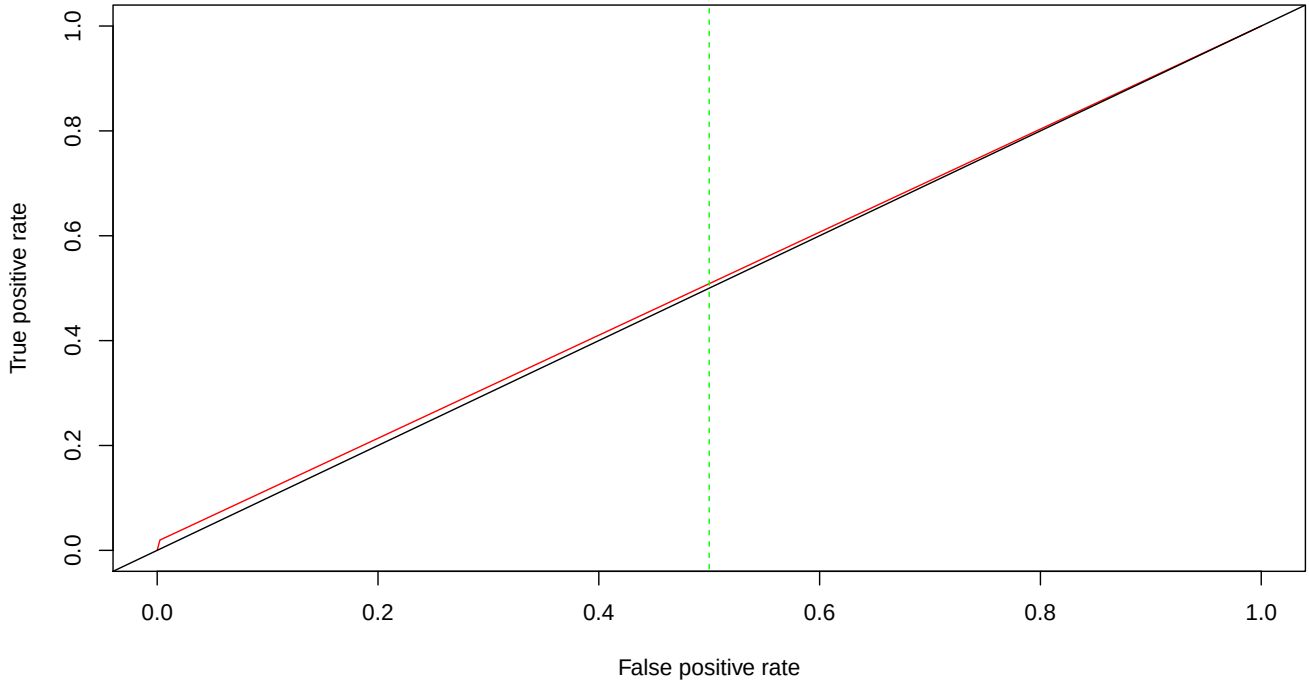

Współczynnik AUC wynosi:

```
[1] 0.5086
```

ROZDZIAŁ 4

NAIWNY KLASYFIKATOR BAYESA

4.1 Dopasowanie modelu i predykcja

Dopasowanie modelu na zbiorze treningowym:

```
bayes <- naiveBayes(class ~ ., data = Train, laplace = 0.2)
```

Predykcja na zbiorze testowym, klasy i prawdopodobieństwo przynależności do klasy 1:

```
bayes_pred <- predict(bayes, newdata = Test)
bayes_prawd <- predict(bayes, newdata = Test, type = "raw")[, 2]
```

4.2 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 738  31
              1  73  20
```

A procent poprawnego dopasowania, czułość i precyzja następująco:

```
procent(tab)

[1] 87.94

czulosc(tab)

[1] 0.2151

precyzja(tab)

[1] 0.3922
```

Pomimo wysokiej czułości i precyzji, naiwny klasyfikator bayesa ma bardzo mały, w porównaniu do innych klasyfikatorów uzytych w tym raporcie, procent poprawnej klasyfikacji. Jednak czułość i precyzja są na bardzo wysokim poziomie, w porównaniu do innych klasyfikatorów!

4.3 Krzywa ROC i współczynnik AUC

I na koniec wyznaczmy krzywą ROC:

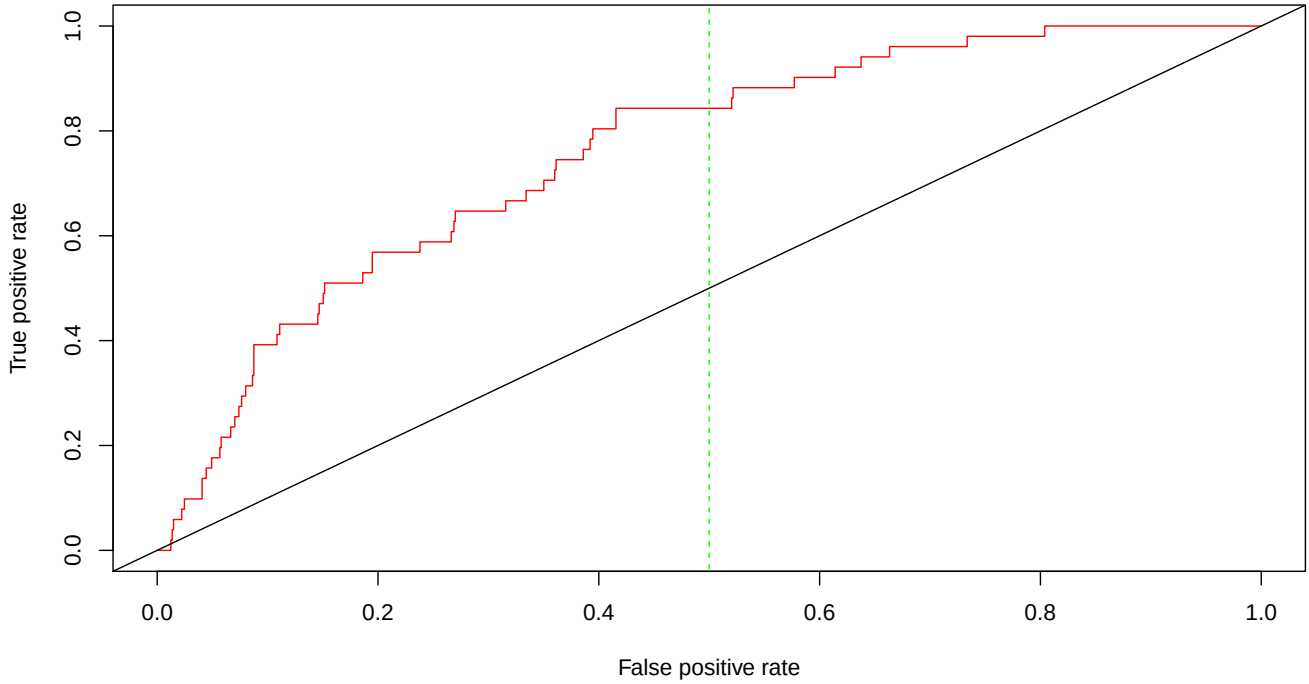

Współczynnik AUC wynosi:

```
[1] 0.7584
```

Piękny wynik!

ROZDZIAŁ 5

METODA K NAJBLIŻSZYCH SĄSIADÓW

5.1 Dopasowanie modelu i predykcja

Dopasujmy metodę k Najbliższych Sąsiadów do naszych danych na zbiorze treningowym:

```
sei_knn <- knn(Train2[, -14], Test2[, -14], cl = Train$class, k = 2)
```

5.2 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
(tab <- tabela(knn(Train2[, -14], Test2[, -14], cl = Train$class, k = 2), Test2$class))

               klasy_prawdziwe
predykcja_klasy   0   1
              0 773  46
              1  38   5
```

A procent poprawnego dopasowania, czułość i precyzja następująco:

```
procent(tab)

[1] 90.26

czulosc(tab)

[1] 0.1163

precyzja(tab)

[1] 0.09804
```

Pomimo dość dobrej poprawnosci procentowej dopasowania, czulosc i precyzja dopasowania sa na bardzo niskim poziomie.

ROZDZIAŁ 6

METODA SVM

6.1 Dopasowanie modelu i predykcja

Dopasujmy model SVM do naszych danych na zbiorze treningowym (przyjmując domyślne parametry i jądro radialne):

```
mod_svm1 <- svm(class ~ ., data = Train, type = "C", kernel = "radial", probability = TRUE)
```

Zróbmy predykcję na zbiorze testowym:

```
pred1 <- predict(mod_svm1, Test, probability = TRUE)
pred_praw1 <- attr(pred1, "probabilities")[, 2]
pred_klas1 <- predict(mod_svm1, Test)
```

6.2 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 811  51
              1   0   0
```

Nasz model zakwalifikował wszystkie obserwacje jako zera! Nie możemy więc tu mówić o dobrym klasyfikatorze. Mimo wszystko spójrzmy jeszcze, jak wygląda procent poprawnego dopasowania, czułość i precyzja:

```
procent(tab1)

[1] 94.08

czulosc(tab1)

[1] 0

precyzja(tab1)

[1] 0
```

Czułość i precyzja są równe zero, czyli rzeczywiście już gorzej być nie może.

6.3 Krzywa ROC i współczynnik AUC

I na koniec wyznaczmy krzywą ROC:

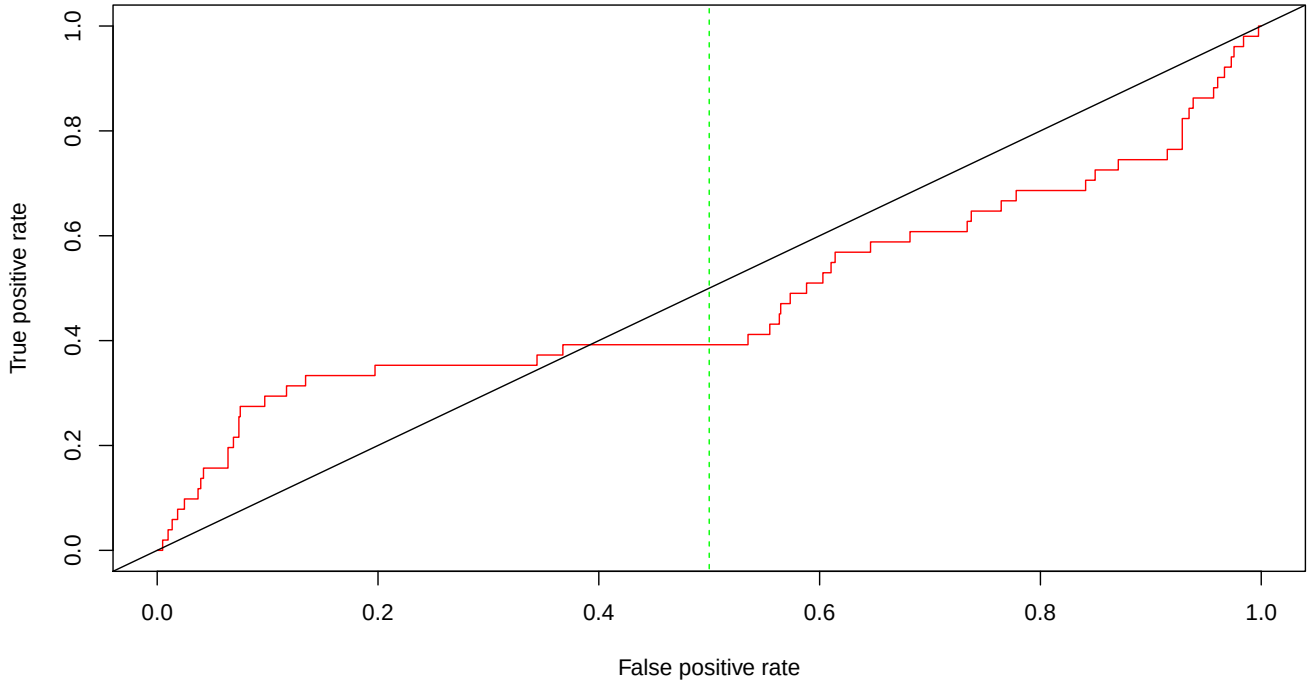

Współczynnik AUC wynosi:

```
[1] 0.483
```

Krzywa ROC i współczynnik AUC sugerują, że model jest gorszy, niż gdybyśmy robili klasyfikację zupełnie losowo!

6.4 Wybór optymalenych parametrów modelu

Spróbujmy więc jakoś poprawić jakość dopasowania. Korzystając z funkcji `tune()` wyznaczmy optymalne parametry modelu:

```
  gamma cost
2     1    2
```

Dopasujmy teraz nowy model SVM, tym razem z optymalnymi parametrami i zróbmy predykcję:

```
mod_svm2 <- svm(class ~ ., data = Train, type = "C", kernel = "radial", gamma = obj$best.parameters[1], cost = obj$best.parameters[
    probability = TRUE)
pred2 <- predict(mod_svm2, Test, probability = TRUE)
pred_praw2 <- attr(pred2, "probabilities")[, 2]
pred_klas2 <- predict(mod_svm2, Test)
```

Tabela reklasyfikacji wygląda następująco:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 803  50
              1   8   1
```

Widać, że jest już lepiej. Sprawdźmy, czy poprawiły się czułość i precyzja:

```
procent(tab2)

[1] 93.27

czulosc(tab2)

[1] 0.1111

precyzja(tab2)

[1] 0.01961
```

Jest zdecydowanie lepiej, ale nadal źle. Spójrzmy na krzywą ROC i parametr AUC:

```
[1] 0.6285
```

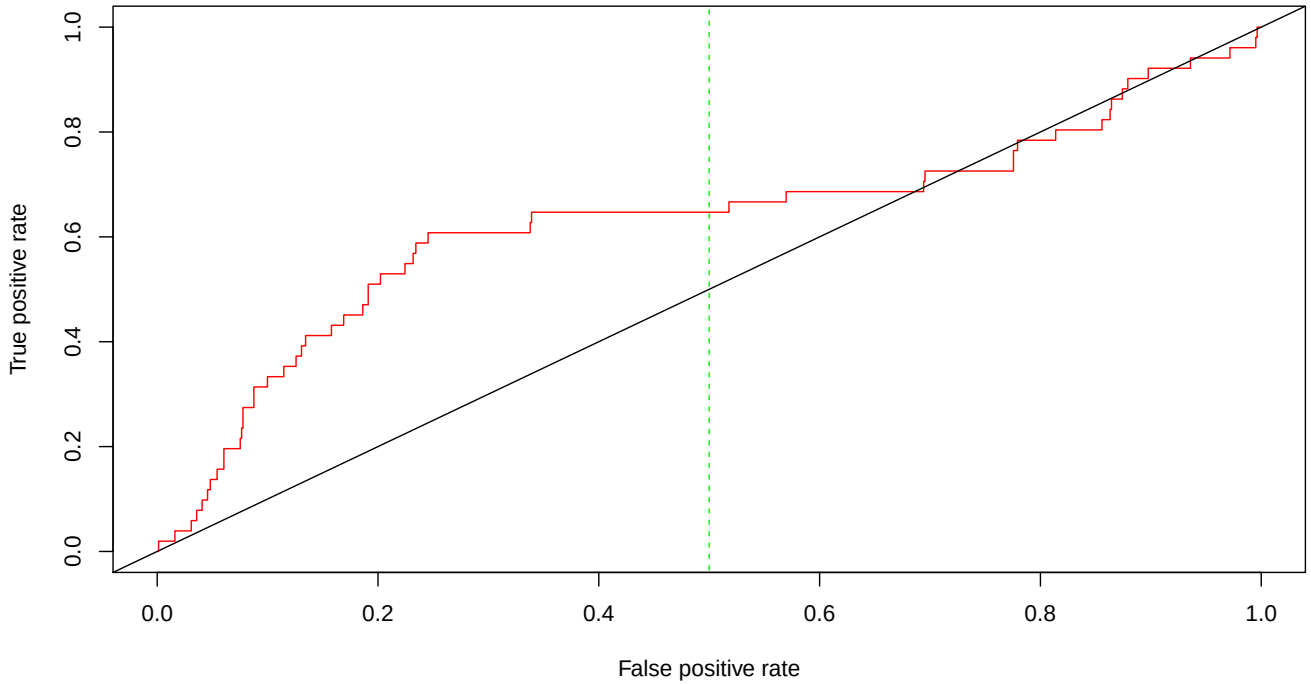

Spróbujmy więc dopasować modele SVM używając różnych funkcji jądrowych.

6.5 Modele SVM z różnymi funkcjami jądrowymi

6.5.1 Jądro liniowe

Dopasowanie modelu i predykcja:

```
mod_svm3 <- svm(class ~ ., data = Train, type = "C", kernel = "linear", gamma = obj$best.parameters[1], cost = obj$best.parameters[
    probability = TRUE)
pred3 <- predict(mod_svm3, Test, probability = TRUE)
pred_praw3 <- attr(pred3, "probabilities")[, 2]
pred_klas3 <- predict(mod_svm3, Test)
```

Tabela reklasyfikacji:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 811  51
              1   0   0
```

I znów wszystko jest klasyfikowane jako zera... Popatrzmy na czułość, precyzję i procent poprawnego dopasowania:

```
procent(tab3)

[1] 94.08

czulosc(tab3)

[1] 0

precyzja(tab3)

[1] 0
```

Wychodzą równe zero, więc model jest fatalny. Mimo to krzywa ROC i parametr AUC tego nie potwierdzają:

```
[1] 0.6797
```

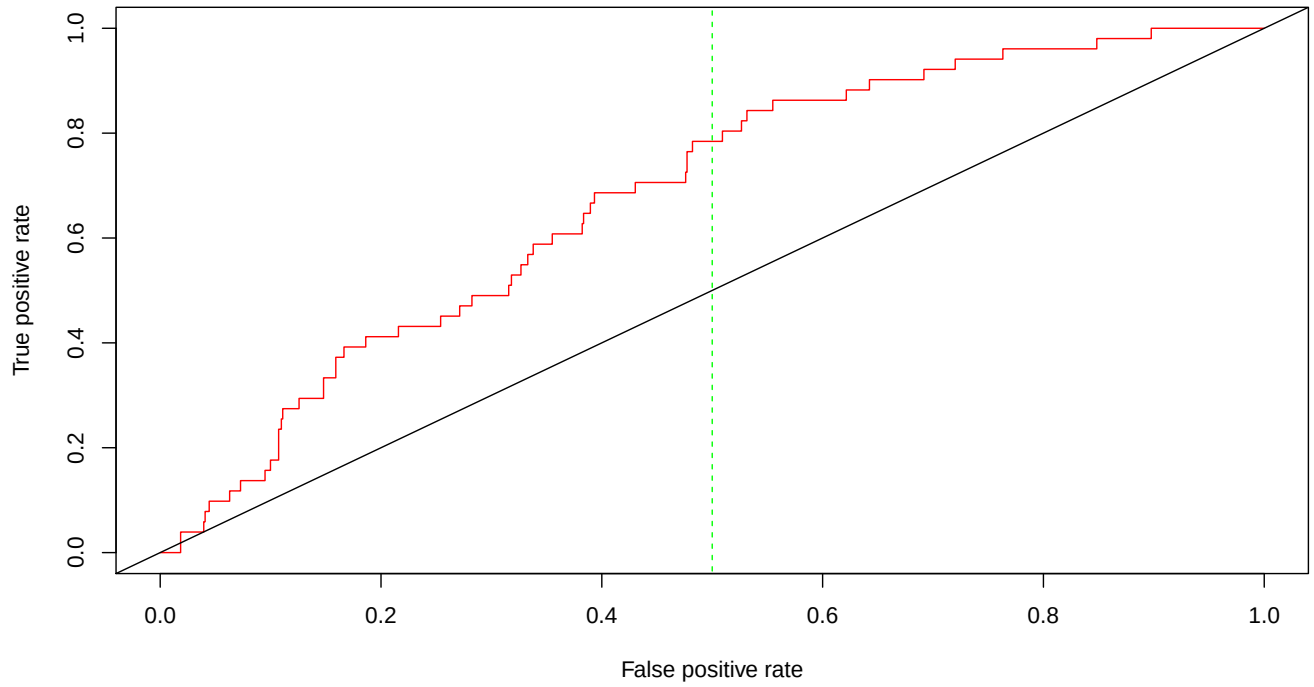

6.5.2 Jądro wielomianowe

Dopasujmy model i zróbmy predykcję:

```
mod_svm4 <- svm(class ~ ., data = Train, type = "C", kernel = "polynomial", gamma = obj$best.parameters[1], cost = obj$best.paramet
    probability = TRUE)
pred4 <- predict(mod_svm4, Test, probability = TRUE)
pred_praw4 <- attr(pred4, "probabilities")[, 2]
pred_klas4 <- predict(mod_svm4, Test)
```

Przyjrzyjmy się tabeli reklasyfikacji:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 759  44
              1  52   7
```

A tak wyglądają czułość, precyzja i procent poprawnej klasyfikacji:

```
procent(tab4)

[1] 88.86

czulosc(tab4)

[1] 0.1186

precyzja(tab4)

[1] 0.1373
```

Jest dużo lepiej. Spójrzmy jeszcze na krzywą ROC i AUC:

```
[1] 0.5564
```

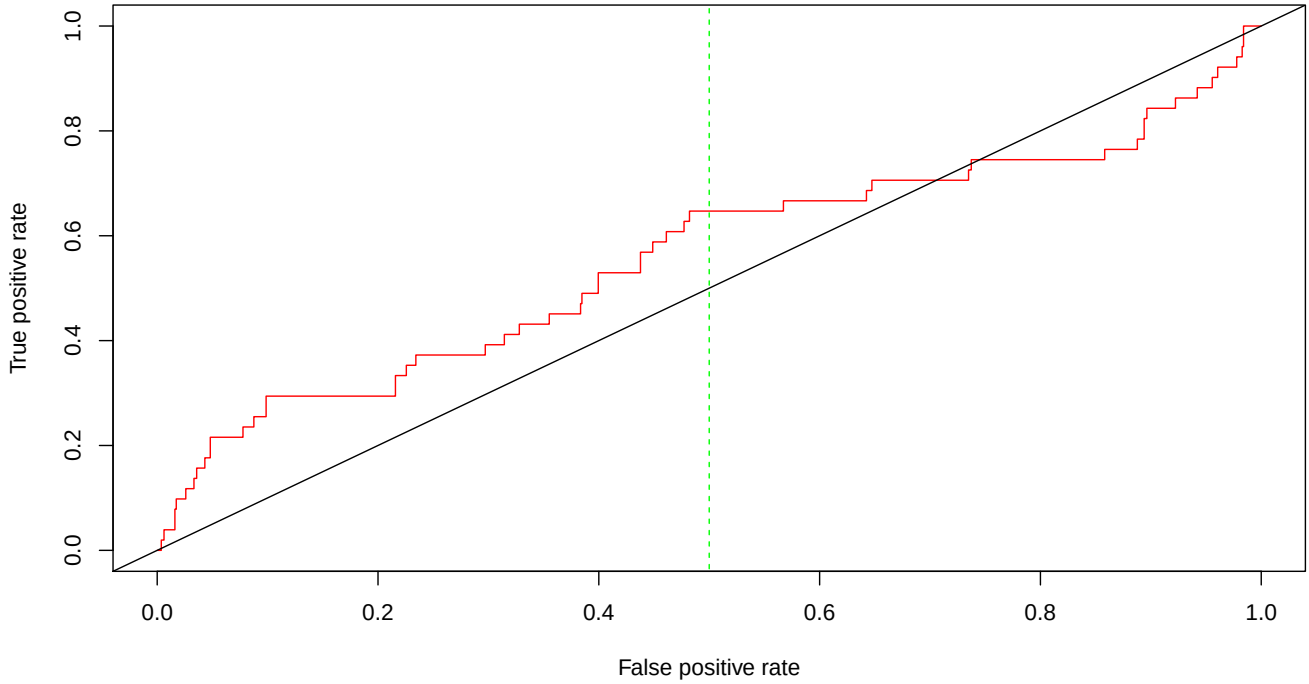

6.5.3 Jądro sigmoidalne

Dopasujmy model i zróbmy predykcję:

```
mod_svm5 <- svm(class ~ ., data = Train, type = "C", kernel = "sigmoid", gamma = obj$best.parameters[1], cost = obj$best.parameters
    probability = TRUE)
pred5 <- predict(mod_svm5, Test, probability = TRUE)
pred_praw5 <- attr(pred5, "probabilities")[, 2]
pred_klas5 <- predict(mod_svm5, Test)
```

Przyjrzyjmy się tabeli reklasyfikacji:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 771  44
              1  40   7
```

A tak wyglądają czułość, precyzja i procent poprawnej klasyfikacji:

```
procent(tab5)

[1] 90.26

czulosc(tab5)

[1] 0.1489

precyzja(tab5)

[1] 0.1373
```

Jest słabiej niż w wielomianowym. Spójrzmy jeszcze na krzywą ROC i AUC:

```
[1] 0.5833
```

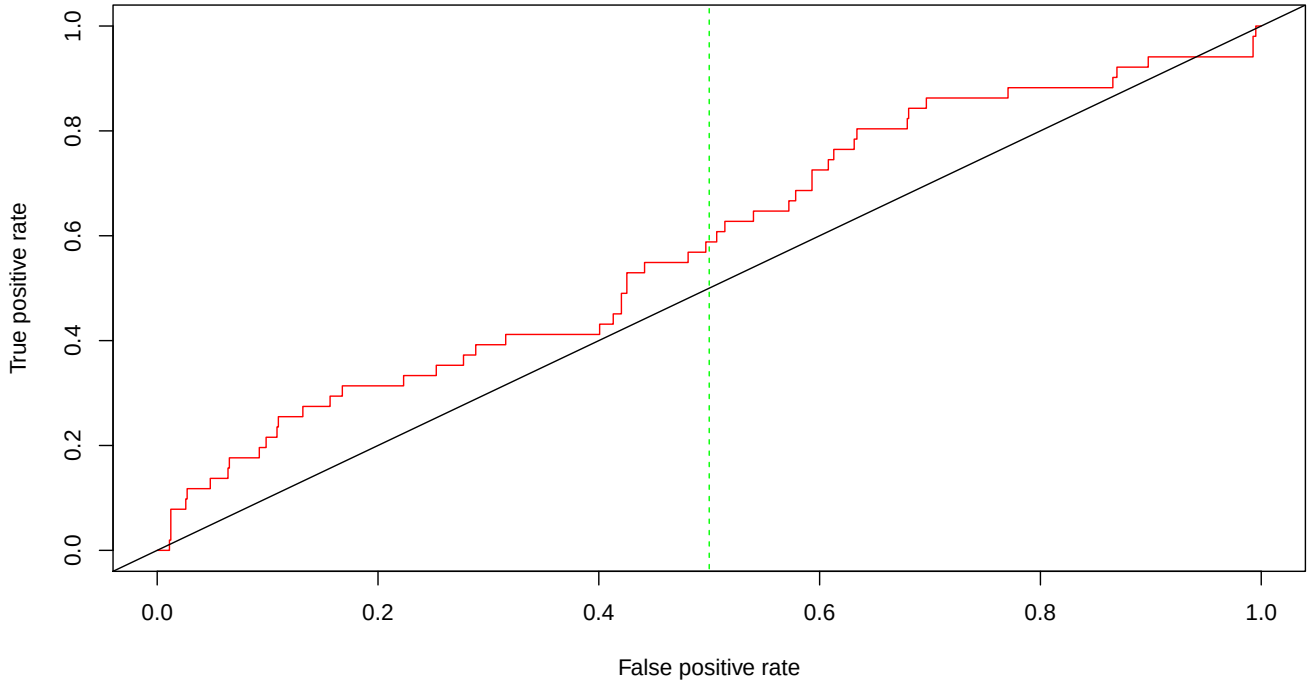

Wygląda na to, że najlepszy okazał się model SVM z jądrem wielomianowym. Ten też zatem będziemy analizować przy porównaniu wszystkich metod.

ROZDZIAŁ 7

DRZEWA DECYZYJNE

7.1 Graficzna prezentacja drzew decyzyjnych

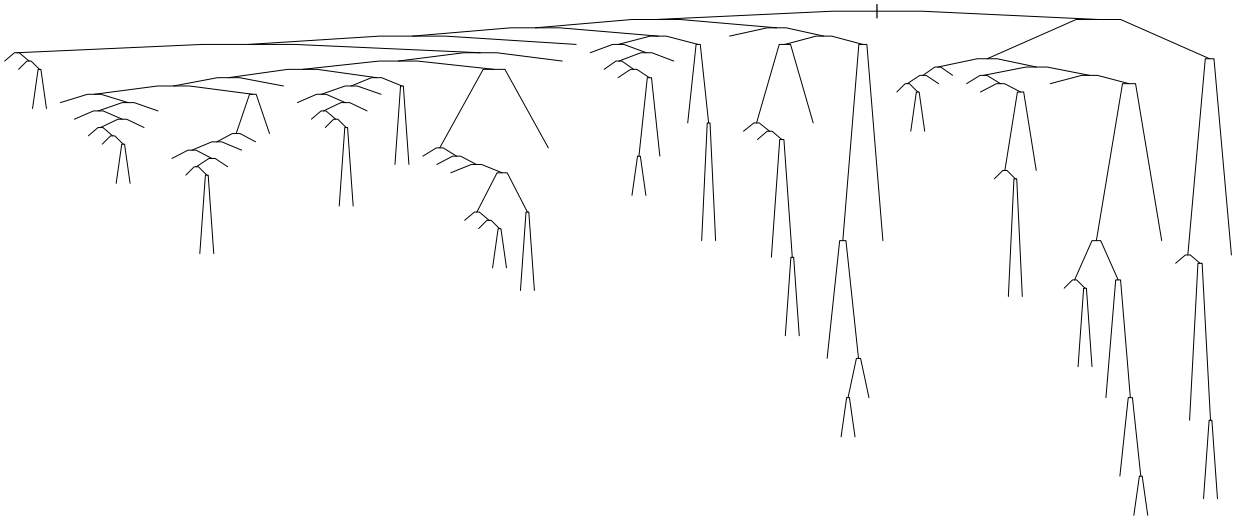

Rysunek 7.1: Drzewo decyzyjne używające indeksu Giniego.

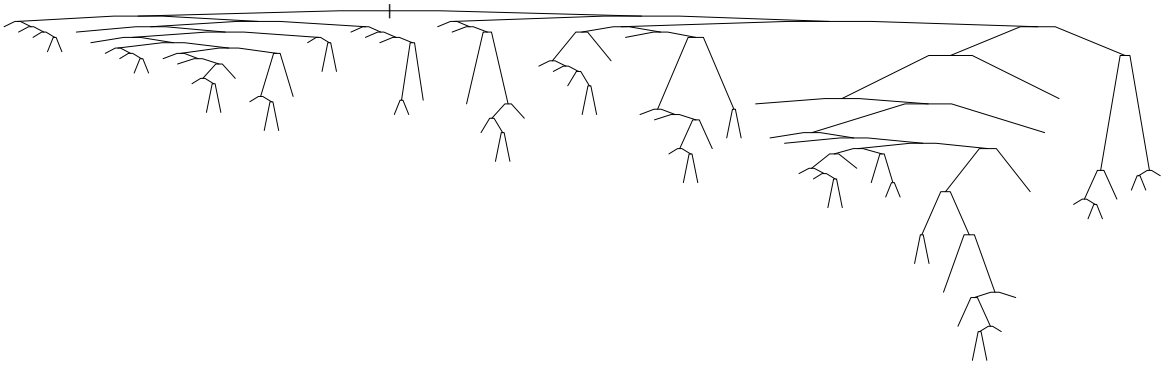

Rysunek 7.2: Drzewo decyzyjne używające entropii.

7.2 Dopasowanie modelu i predykcja

Dopasowanie klasyfikacji przy pomocy drzewa decyzyjnego używającego indeksu Giniego ma syntax jak poniżej:

```
Seismic.tree <- rpart(class ~ ., data = Train, cp = 1e-04, minsplit = 5)
```

Graficzne przedstawienie drzewa zaś ma postać 7.1.

Dopasowanie klasyfikacji przy pomocy drzewa decyzyjnego używającego entropii ma syntax jak poniżej:

```
Seismic.tree.ent <- rpart(class ~ ., data = Train, cp = 1e-04, minsplit = 5, parms = list(split = "information"))
```

Z kolei przedstawienie tego drzewa ma postać 7.2.

7.2.1 Wybór drzewa optymalnego

Wybieramy drzewo optymalne w oparciu o kryterium kosztu- złożoności, stosując regułę `1SE`.

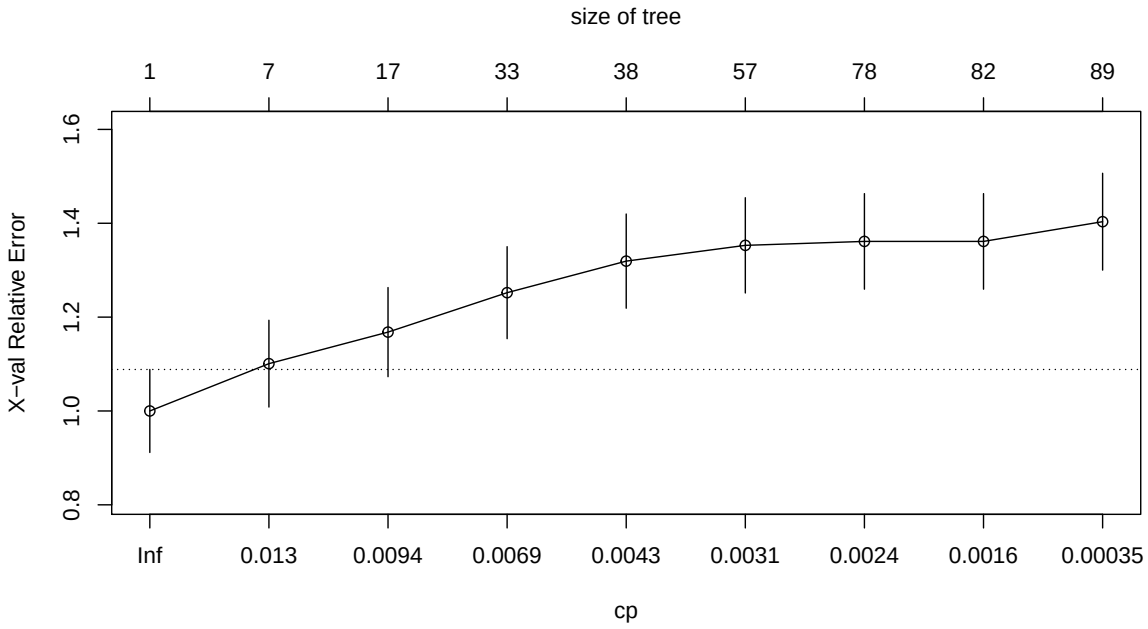

"A good choice of cp for pruning is often the leftmost value for which the mean lies below the horizontal line." - w takim wypadku nie trzeba przycinać drzewa.

Wykorzystajmy jeszcze funkcję `tune.rpart()` do wyliczenia optymalnego argumentu `minsplit`, który wyniósł 12.

```
obj <- tune.rpart(class ~ ., data = Train, minsplit = c(1:15))
summary(obj)


Parameter tuning of 'rpart.wrapper':

- sampling method: 10-fold cross validation

- best parameters:
 minsplit
       12

- best performance: 0.07726

- Detailed performance results:
   minsplit   error dispersion
1         1 0.08248    0.01937
```

```
2          2 0.08248    0.01937
3          3 0.08248    0.01937
4          4 0.08248    0.01937
5          5 0.08132    0.01904
6          6 0.08074    0.01833
7          7 0.08016    0.01860
8          8 0.08016    0.02070
9          9 0.08016    0.02070
10        10 0.08016    0.02070
11        11 0.07784    0.02022
12        12 0.07726    0.02000
13        13 0.07784    0.02095
14        14 0.07959    0.02379
15        15 0.07901    0.02350
```

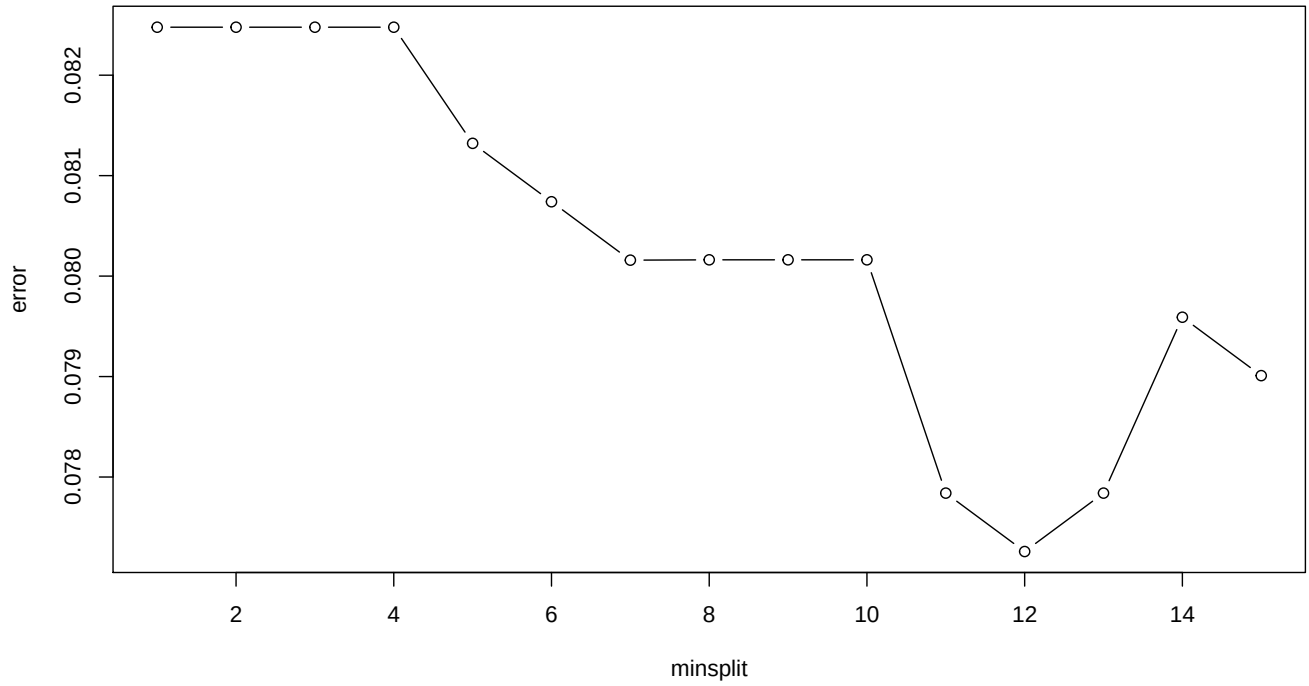

Rysunek 7.3: Performance of rpart.wrapper !

Widać to również na wykresie Performance of rpart.wrapper !, dla którego minimum jest osiągane w punkcie 12. Zatem najoptymalniejszy model dla drzewa klasyfikacyjnego to:

```
Seismic.tree <- rpart(class ~ ., data = Train, cp = 1e-04, minsplit = 12)
```

7.2.2 Predykcja dla optymalnego drzewa

Predykcja dla tak dopasowanego drzewa wygląda następująco:

```
pred.tree.class <- predict(Seismic.tree, newdata = Test, type = "class")
pred.tree.prob <- predict(Seismic.tree, newdata = Test, type = "prob")[, 2]
```

7.3 Diagnostyka modelu

Tabela reklasyfikacji na zbiorze testowym wygląda następująco:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 784  45
              1  27   6
```

A procent poprawnego dopasowania, czułość i precyzja następująco:

```
procent(tab)
```

```
[1] 91.65
```

```
czulosc(tab)
```

```
[1] 0.1818
```

```
precyzja(tab)
```

```
[1] 0.1176
```

Pomimo w miarę dobrego poziomu procentowej poprawności klasyfikacji i dość dużej czułości w stosunku to poprzednich klasyfikatorów, optymalne drzewo regresyjne ma bardzo słabą precyzję.

7.4 Krzywa ROC i współczynnik AUC

I na koniec wyznaczmy krzywą ROC:

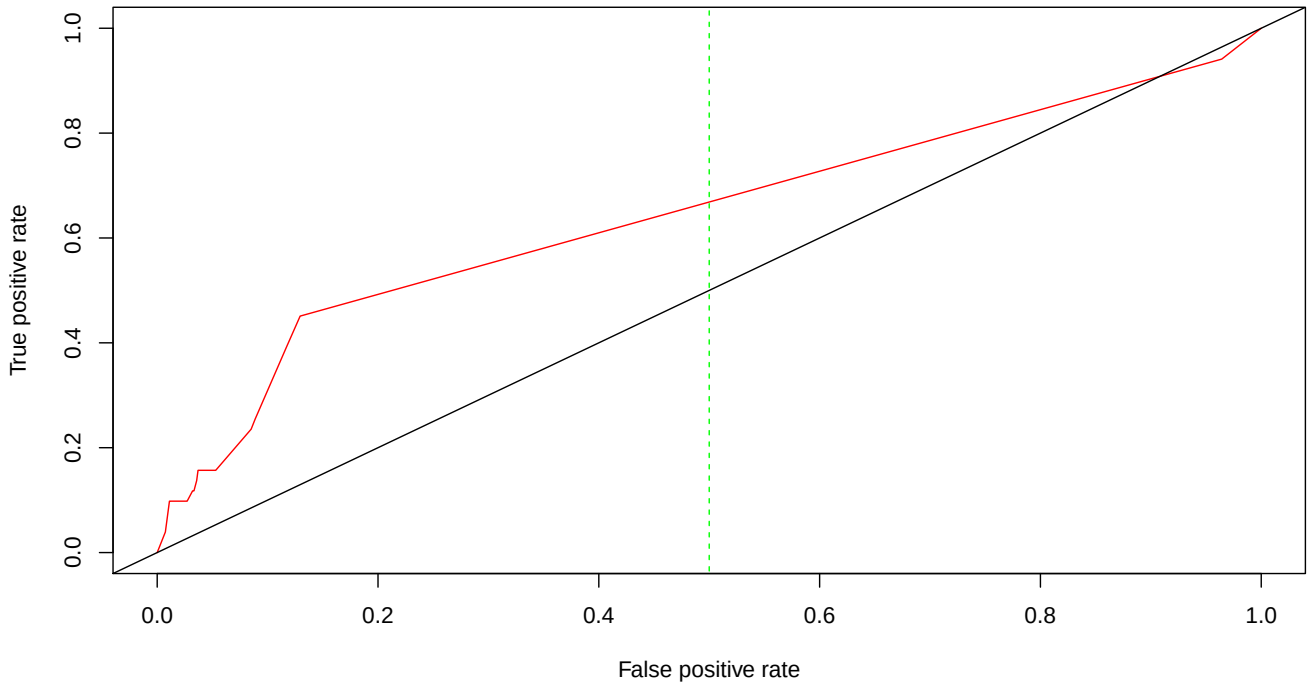

Współczynnik AUC wynosi:

```
[1] 0.643
```

ROZDZIAŁ 8

METODY ŁĄCZENIA DRZEW DECYZYJNYCH

8.1 Bagging

Dopasujmy model opierając się na baggingu dla drzew decyzyjnych:

```
mod_bag <- bagging(class ~ ., data = Train)
```

Zróbmy predykcję:

```
predykcja <- predict.bagging(mod_bag, newdata = Test)
pred_klas <- predykcja$class
pred_praw <- predykcja$prob[, 2]
```

Popatrzmy na tabelę klasyfikacji na zbiorze testowym:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 810  50
              1   1   1
```

I na procent poprawnego dopasowania, czułość i precyzję:

```
procent(tab)

[1] 94.08

czulosc(tab)

[1] 0.5

precyzja(tab)

[1] 0.01961
```

Czułość jest nienajgorsza. Za to precyzja jest fatalna. Przyjrzyjmy się jeszcze krzywej ROC i współczynnikowi AUC:

```
[1] 0.7345
```

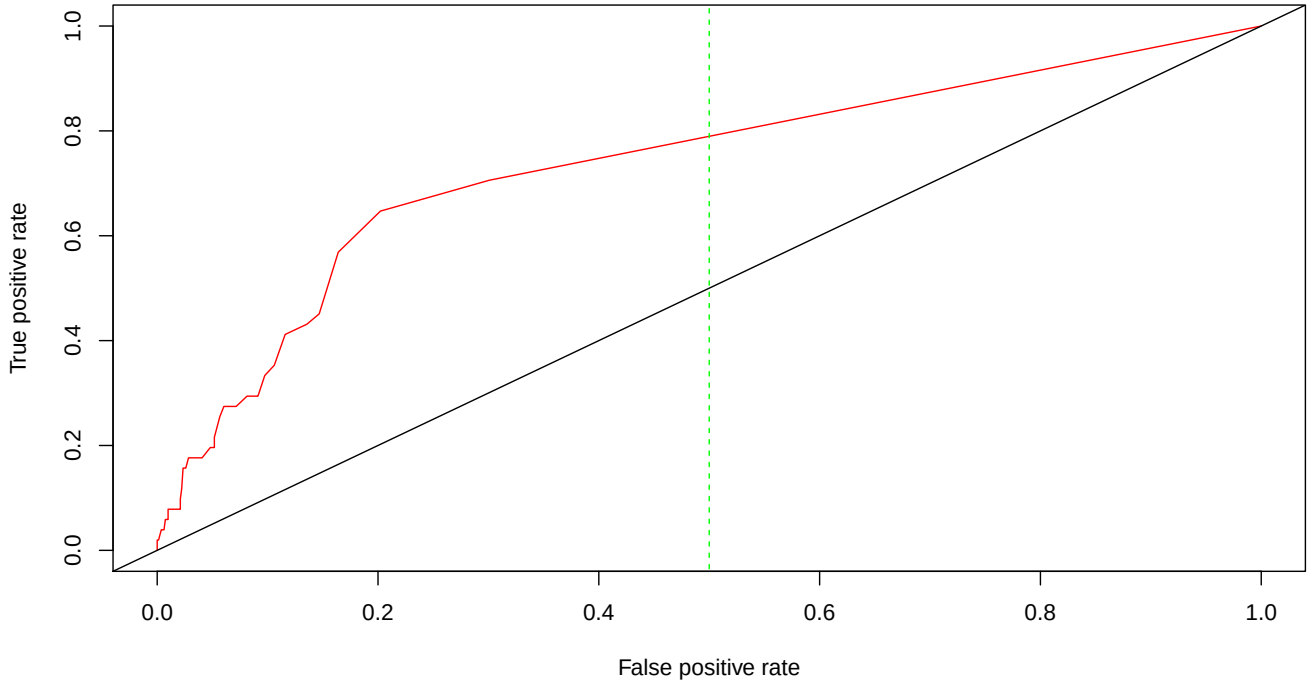

Wygląda to całkiem dobrze.

8.2 Boosting

Dopasujmy model opierając się na boostingu dla drzew decyzyjnych:

```
mod_boo <- boosting(class ~ ., data = Train, control = (minsplit = 10), mfinal = 20)
```

Zróbmy predykcję na zbiorze testowym:

```
predykcja <- predict.boosting(mod_boo, newdata = Test)
pred_klas <- predykcja$class
pred_praw <- predykcja$prob[, 2]
```

I przyjrzyjmy się tabeli klasyfikacji na zbiorze testowym:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 799  47
              1  12   4
```

Inne współczynniki wyglądają następująco:

```
procent(tab)

[1] 93.16

czulosc(tab)

[1] 0.25

precyzja(tab)

[1] 0.07843
```

Nie jest najlepiej...
Spójrzmy jeszcze na krzywą ROC i współczynnik AUC:

```
[1] 0.6931
```

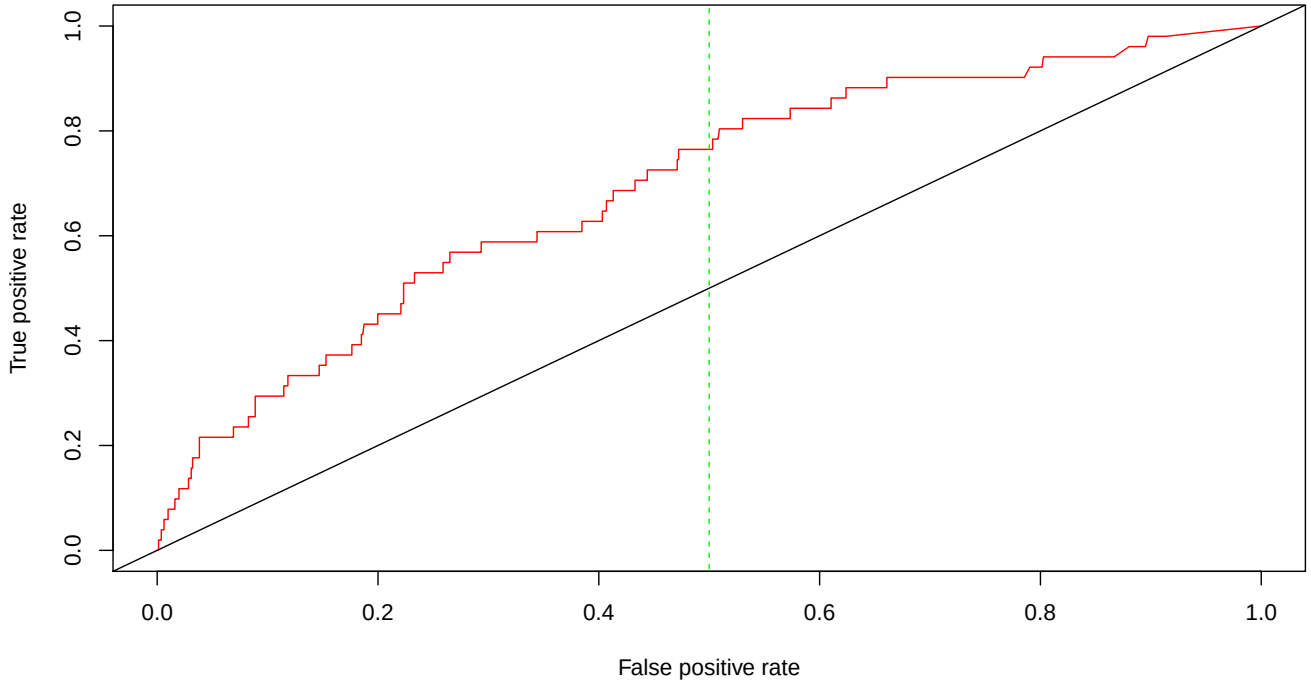

8.3 Lasy losowe

Dopasumy do danych las losowy w następujący sposób:

```
mod_las <- randomForest(class ~ ., data = Train)
```

Zróbmy predykcję:

```
pred_praw <- predict(mod_las, newdata = Test, type = "prob")[, 2]
pred_klas <- predict(mod_las, newdata = Test, type = "response")
```

Przyjrzyjmy się tabeli reklasyfikacji:

```
               klasy_prawdziwe
predykcja_klasy   0   1
              0 807  49
              1   4   2
```

Oraz innym współczynnikom:

```
procent(tab)

[1] 93.85

czulosc(tab)

[1] 0.3333

precyzja(tab)

[1] 0.03922
```

Czułość jest na dobrym poziomie, natomiast precyzja w dalszym ciągu jest bardzo zła...
Zobaczmy jeszcze krzywą ROC i współczynnik AUC:

```
[1] 0.7422
```

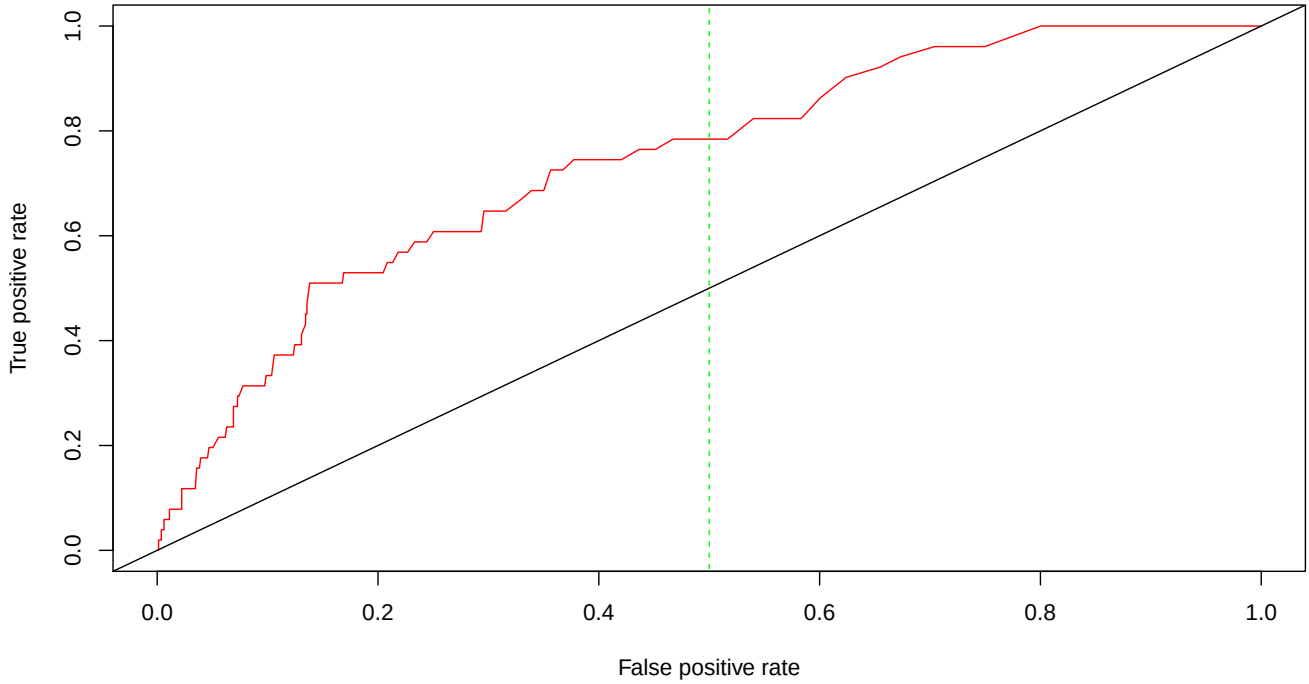

Krzywa ROC wygląda bardzo dobrze.

Na poniższym wykresie zobaczmy jeszcze, które zmienne są najbardziej istotne (te, co znajdują się na górze wykresu są najbardziej istotne).

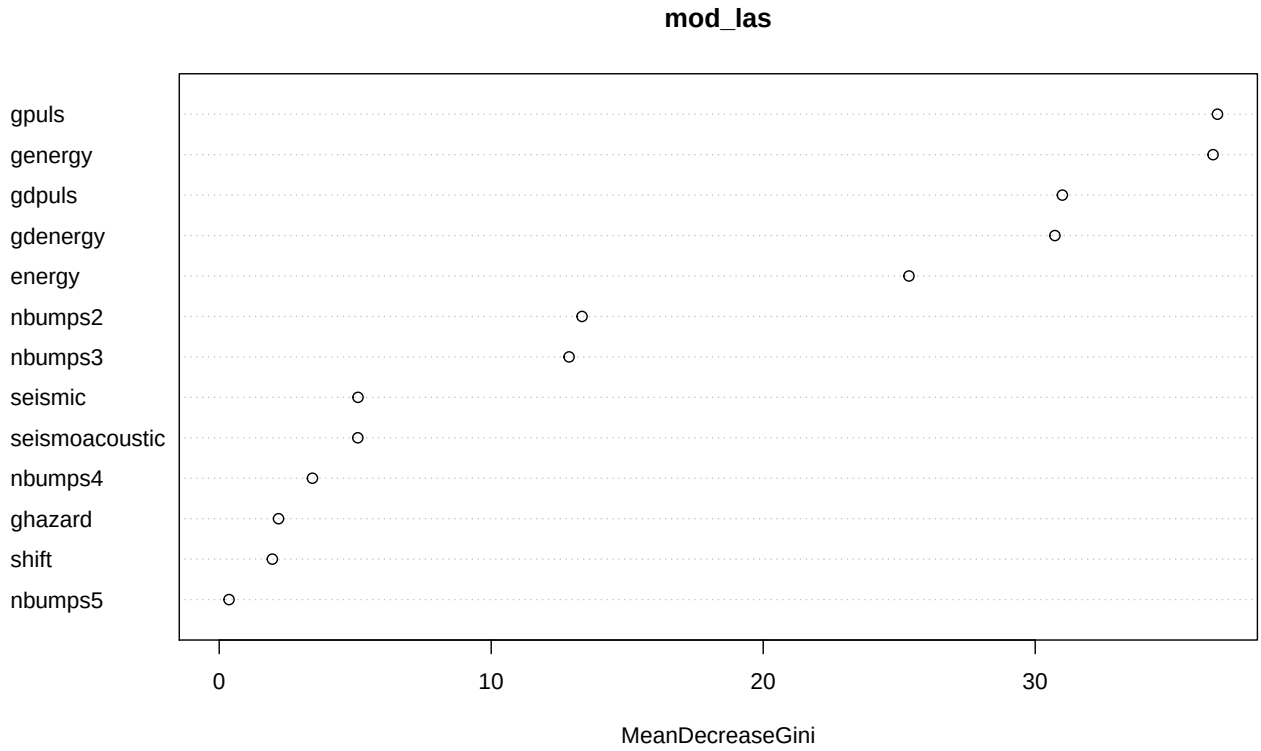

Zestawienie wyników dla klasyfikatorów użytych do analizy

ROZDZIAŁ 9

KRZYWE ROC

Wszystkie krzywe ROC dla klasyfikatórw wyglądają następująco. Najlepiej spisuje się Naiwny Klasyfikator Bayesa.

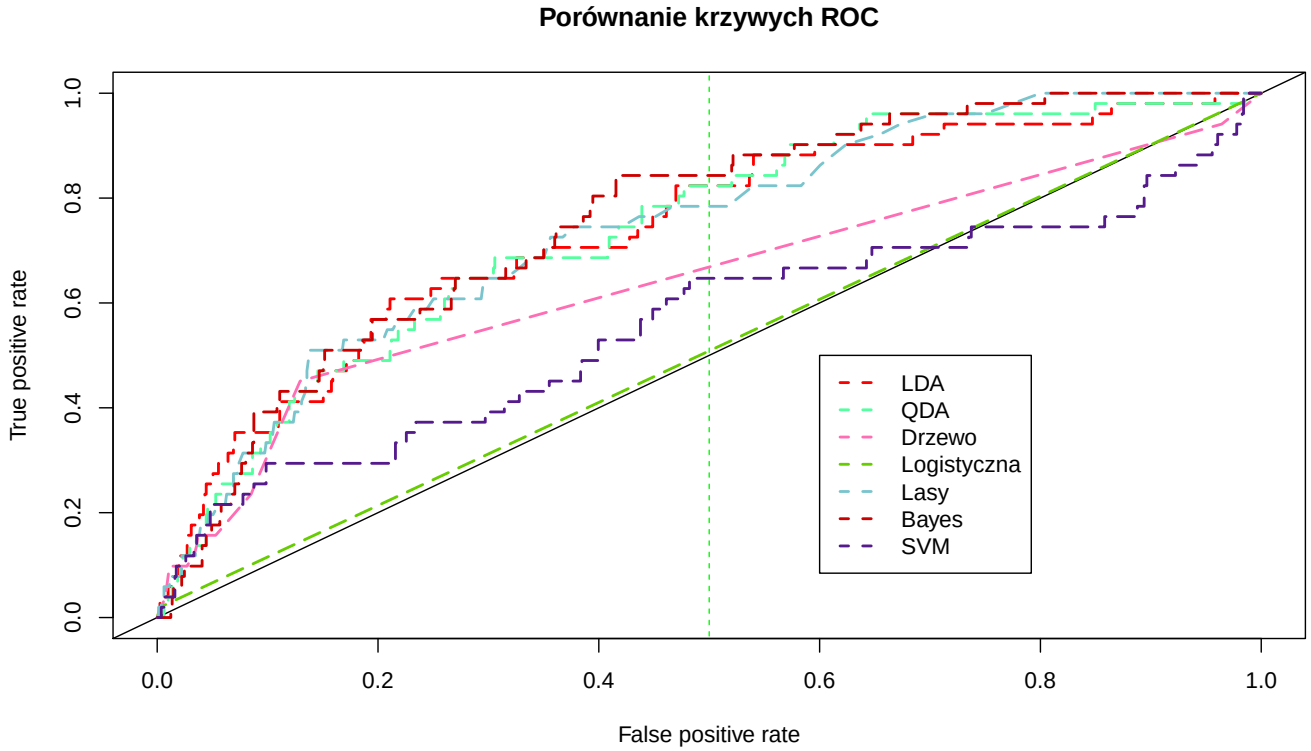

ROZDZIAŁ 10

TABELA PODSUMOWUJĄCA

	Procent [1]	Czułość	Precyzja	AUC
lda	92.69	0.25	0.12	0.74
qda	87.12	0.18	0.33	0.74
logit	93.97	0.33	0.02	0.51
bayes	87.94	0.22	0.39	0.76
knn	90.26	0.12	0.10	-
svm	88.86	0.12	0.14	0.56
tree	91.65	0.18	0.12	0.64
bagging	94.08	0.50	0.02	0.73
boosting	93.16	0.25	0.08	0.69
las	93.85	0.33	0.04	0.74

Z powyższej tabeli widać wyraźnie, że najlepiej spisuje się klasyfikator naiwnego Bayesa. Ma on najwyższą precyzję (i to znacznie większą niż wszystkie pozostałe metody!) i najwyższą wartość parametru AUC. Jego czułość też należy raczej do tych lepszych. Niestety charakteryzuje się jednym z najniższych procentów poprawnej klasyfikacji. Patrząc jednak na precyzję i krzywą ROC możemy zdecydowanie stwierdzić, że jest on metodą, która najlepiej stosuje się do naszych danych. Precyzja jest tu ważna głównie ze względu na charakter naszych danch. Mianowicie zależy nam przede wszystkim na poprawnym wykryciu wstrząsów sejsmicznych. Czyli lepiej jest dla nas ogłosić fałszywy alarm, niż rzeczywistego trzęsienia nie wykryć.

Pozostałe metody sprawują się niestety nie najlepiej (a niektóre wręcz fatalnie!).

[1] tzn. procent poprawnej klasyfikacji